Langage C

Arnaud Sangnier
sangnier@irif.fr

Les chaînes de caractères

Les littéraux chaînes de caractères

- En C, il n'y a pas à proprement parlé un type chaîne de caractères.
- Mais il y a des litéraux chaînes de caractères, par exemple :

```
"Hello\n", "Blabla blabla", "1234\n256"
```

- Moralement ils correspondent à un tableau de caractères dont le dernier élément est **le caractère spécial '\0'**.
- Ces littéraux chaînes de caractères ne peuvent pas être changés tels quels, ils sont 'read-only '
  - On verra par la suite qu'en fait on peut changer l'intérieur de chaînes de caractères, mais il faudra faire attention d'où sont stockés ces chaînes.
  - Le compilateur ne détecte pas de telles modifications interdites
  - Si on essaie de les modifier tel quel, on aura à l'exécution une erreur **bus error**

Les littéraux chaînes de caractères

- En pratique, pour les stocker dans une variable, on peut faire :

```
char *s="Hello!"
```

- Dans ce cas, le pointeur s pointe vers une zone de la mémoire **read-only** (non modifiable)
- Cette zone est une zone de 7 caractères dont le dernier caractère est '\0'

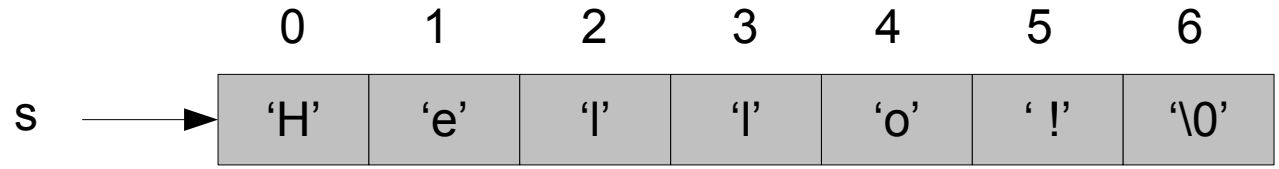

NON MODIFIABLE

- **Attention :** le caractère '\0' est différent du caractère '0'
- En revanche, on peut lire les éléments de la zone

Exemple

```
#include <stdio.h>
#include <stdlib.h>

int main () {
  char *test="abcd";
  for (char *p=test;p<test+4;++p){
    printf("%c ",*p);
  }
  printf("\n");
  return EXIT_SUCCESS;
}
```

string-literal.c

Exemple

```
#include <stdio.h>
#include <stdlib.h>

int main () {
  char *test="abcd";
  *(test+1)='f';
  printf("%s \n",test);
  return EXIT_SUCCESS;
}
```

string-literal2.c

Génère à l'exécution une error : bus error
-> modification d'un endroit de la mémoire non autorisé

Exemple

```
#include <stdio.h>
#include <stdlib.h>

void change(char *st){
  *st='E';
}

int main () {
  char *test="abcd";
  change(test);
  for (char *p=test;p<test+4;++p){
    printf("%c ",*p);
  }
  printf("\n");
  return EXIT_SUCCESS;
}
```

string-literal3.c

Génère à l'exécution une error : bus error
-> modification d'un endroit de la mémoire non autorisé

Utilisation de tableaux

- On peut aussi stocker un littéral chaîne de caractères dans un tableau :

```
char s[7]="Hello!";
```

- Ou :

```
char s[]="Hello!";
```

- Il faut faire attention que le tableau soit assez grand et laisser de la place à la fin pour le caractère '\0'
- En pratique, la chaîne de caractères (de longueur L) est copié dans les cases d'un tableau de taille L+1 et dans la (L+1)-ème case, le caractère '\0' est aussi copié.
- Cette zone est une zone de 7 caractères dont le dernier caractère est '\0'

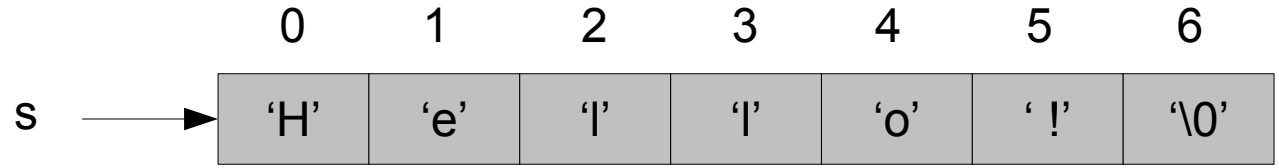

- **Avantage :** on peut modifier les cases du tableau
- **Inconvénient :** s indique tableau et donc son utilisation est restreint (on ne peut pas faire d'affectation par exemple)

Exemple

```
#include <stdio.h>
#include <stdlib.h>

int main () {
  char test[5]="abcd";
  *test='E';
  *(test+1)='F';
  for (char *p=test;p<test+4;++p){
    printf("%c ",*p);
  }
  printf("\n");
  return EXIT_SUCCESS;
}
```

string-tab.c

Tableaux de chaînes de caractères

- On peut faire des tableaux de chaînes de caractères :

```
char *s[3]={"Hello!","World","Monde"};
```

- Dans ce cas, chaque case du tableau contient un ‘pointeur’ vers une chaîne de caractères non modifiables
- Quand on le passe en argument à une fonction on aura cette fois ci-bien le type char ** car il s’agit bien d’un tableau de pointeurs !

Exemple

```
#include <stdio.h>
#include <stdlib.h>

void f(char **t){
  for(size_t i=0;i<3;++i){
    printf("%s\n",*(t+i));
  }
}

int main () {
  char *test[3]={"abcd","blabla","hello"};
  f(test);
  return EXIT_SUCCESS;
}
```

string-tab-tab.c

Exemple

```
#include <stdio.h>
#include <stdlib.h>

void f(char **t){
  for(size_t i=0;i<3;++i){
    printf("%s\n",*(t+i));
  }
}

int main () {
  char *test[3]={"abcd","blabla","hello"};
  *(*test)='C';
  f(test);
  return EXIT_SUCCESS;
}
```

string-tab-tab2.c

Génère à l'exécution une error : bus error

En pratique

- On utilisera pour manipuler des chaînes de caractères
  - des littéraux chaînes de caractères
    - En se rappelant qu'ils sont non modifiables
  - Des tableaux de caractères
  - Des zones dans le tas mémoire allouées dynamiquement contenant des caractères
- Il faudra faire attention au point suivant :
  - **Quand on encode/manipule une chaîne de caractères, on suppose toujours que**
    - **Elle ne contient pas le caractère '\0'**
    - **Elle se termine par le caractère '\0'**
- Toutes les fonctions manipulant des chaînes de caractères prennent en compte ces hypothèses et ont un comportement non spécifiés si les hypothèses ne sont pas respectés
- Un tableau de caractères quelconque peut lui très bien contenir plusieurs occurences de '\0' mais il ne faut pas le considérer comme une chaîne

Exemple

```
#include <stdio.h>
#include <stdlib.h>

int main () {
  char tab[4]={'A','\0','B','\0'};
  printf("%s \n",tab);
  char tab2[4]="ABC";
  printf("%s \n",tab2);
  return EXIT_SUCCESS;
}
```

tab-vs-string.c

```
>../tab-vs-string
A
ABC
```

Dans le printf,%s atted une chaîne de caractères et s'arrète donc pour tab au premier '\0'

Manipulation

- La plupart des fonctions de manipulation de chaînes de caractères se trouvent dans **<string.h>**
- Certaines fonctions modifient la chaîne donnée entrée et d'autres non
- Pour les fonctions qui ne modifient pas la chaîne dans la signature de la fonction on a le mot clef const
- Par exemple, fonction pour connaître la taille du chaîne :
  - **size_t strlen(const char *s);**
- Cette fonction renvoie le nombre de caractère dans la chaîne sans prendre en compte le dernier caractère '\0'

```
char *s="Hello!"
size_t taille=strlen(s);
```

- Dans taille on aura la valeur 6.

Exemple

```
#include <stdio.h>
#include <stdlib.h>
#include <string.h>

int main () {
  char *st="ABRA CADA BRA!";
  size_t lo=strlen(st);
  printf("%s Taille : %zu\n",st,lo);
  lo=strlen(st+4);
  printf("%s Taille : %zu\n",st+4,lo);
  char st2[]="ABCD";
  lo=strlen(st2);
  printf("%s Taille : %zu\n",st2,lo);
  *(st2+2)='\0';
  lo=strlen(st2);
  printf("%s Taille : %zu\n",st2,lo);
  return EXIT_SUCCESS;
}
```

string-long.c

Reprogrammer strlen

```
size_t longueur(char *);

int main () {
  char *st="ABRA CADA BRA!";
  size_t lo=longueur(st);
  printf("%s Taille : %zu\n",st,lo);
  return EXIT_SUCCESS;
}

size_t longueur(char *s){
  size_t i=0;
  while(*s){
    ++s;
    ++i;
  }
  return i;
}
```

string-long2.c

Copie de zone mémoire

Rappel du dernier cours

- On peut copier des zones mémoire, et on a deux fonctions (elle sont **dans <string.h>**) :
  - `void *memmove(void *dst, const void *src,size_t len)`
  - `void *memcpy(void *dst, const void *src,size_t len)`
- Elles copie toutes les deux len octets de src vers dst
- **Les deux zones pointées doivent être allouées et de la bonne taille** (inférieure ou égale à len)
- Elles renvoient toutes les deux dst
- Différence :
  - Pour memcpy, les deux zones pointées par dst et src ne doivent pas se chevaucher !

Exemple

```
#include <stdio.h>
#include <stdlib.h>
#include <string.h>

int main () {
  char *st="ABRA CADA BRA!";
  char *st2=" MAGIE!!!";
  char*st3=malloc((strlen(st)+strlen(st2)+1)*sizeof(char));
  memcpy(st3,st,strlen(st)*sizeof(char));
  memcpy(st3+strlen(st),st2,(strlen(st2)+1)*sizeof(char));
  printf("%s\n",st3);
  return EXIT_SUCCESS;
}
```

string-concat.c

Exemple

```c
#include <stdio.h>
#include <stdlib.h>
#include <string.h>
#include <assert.h>

char *concat_tab(char **,size_t n);

int main () {
  char *st[3]={"ABRA","CADA","BRA!"};
  char *st2=concat_tab(st,3);
  printf("%s\n",st2);
  return EXIT_SUCCESS;
}

/*Fonction qui concatene les chaines*/
/*D'un tableau de chaine de caracteres de taille n*/
char *concat_tab(char **t,size_t n){
  size_t taille=0;
  for(char **tmp=t;tmp<t+n;++tmp){
    taille+=strlen(*tmp);
  }
  char *res=malloc((taille+1)*sizeof(char));
  assert(res!=NULL);
  size_t pos=0;
  for(char **tmp=t;tmp<t+n;++tmp){
    memcpy(res+pos,*tmp,strlen(*tmp));
    pos+=strlen(*tmp);
  }
  *(res+taille)='\0';
  return res;
}
```

string-concat2.c

La fonction strcat

- La fonction
  - `char *strcat(char *restrict s1, const char *restrict s2);`
- Elle concatène la chaîne de caractères s2 à la fin de la chaîne de caractères s1 (en mettant le '\0' à la fin de la concaténation)
- Renvoie le pointeur s1
- Il faut que les deux chaînes se terminent par '\0'
- Il faut qu'il y ait assez de place dans la zone pointée par s1
- **ATTENTION** aux débordement en utilisant cette fonction (si il n'y a pas assez de place dans s1 par exemple)
- Sa variante
  - `char *strncat(char *restrict s1, const char *restrict s2, size_t n);`
  - Copie au plus n caractères de s2 et ajoute '\0' ensuite

Exemple

```
#include <stdio.h>
#include <stdlib.h>
#include <string.h>
#include <assert.h>


int main () {
  char *s="HELLO";
  char *s2=" BOB ";
  char *s3="OR WORLD!";
  size_t taille=strlen(s)+strlen(s2)+strlen(s3);
  char *st=malloc((taille+1)*sizeof(char));
  *st='\0';
  strcat(st,s);
  strcat(st,s2);
  strcat(st,s3);
  printf("%s\n",st);

}
```

string-strcat.c

Exemple

```
#include <stdio.h>
#include <stdlib.h>
#include <string.h>
#include <assert.h>


int main () {
  char *s="HELLO";
  char *s2=" BOB ";
  char *s3="OR WORLD!";
  size_t taille=7;
  char *st=malloc((taille+1)*sizeof(char));
  *st='\0';
  strncat(st,s,2);
  strncat(st,s2,3);
  strncat(st,s3,2);
  printf("%s\n",st);
}
```

string-strncat.c

Copie de chaînes de caractères

- La fonction
  - `char *strcpy(char *dst, const char *src);`
- Elle copie la chaîne pointée par src dans dst, y compris le caractère de fin de chaîne '\0'
- Elle renvoie le pointeur dst
- Il faut que dst pointe vers une zone allouée modifiable
- Il faut qu'il y ait assez de place dans la zone pointée par dst
- Sa variante
  - `char *strnpy(char * dst, const char * src, size_t len);`
  - Copie au plus len caractères de s2
  - Si src à moins de len caractères, elle complète en rajoutant des '\0'
  - Sinon, il se peut que la chaîne copiée n'est pas de caractères de fin de chaîne

Exemple

```
#include <stdio.h>
#include <stdlib.h>
#include <string.h>
#include <assert.h>

int main () {
  char *st=malloc(100*sizeof(char));
  strcpy(st,"HELLO");
  printf("%s\n",st);
  return EXIT_SUCCESS;
}
```

string-strcpy.c

Exemple

```
#include <stdio.h>
#include <stdlib.h>
#include <string.h>
#include <assert.h>

int main () {
  char *st=malloc(100*sizeof(char));
  strcpy(st,"HELLO");
  printf("%s\n",st);
  strcpy(st,"On met une phrase longue");
  printf("%s\n",st);
  strncpy(st,"HELLO",3);
  printf("%s\n",st);
  strcpy(st,"HELLO");
  printf("%s\n",st);
  return EXIT_SUCCESS;
}
```

string-strcpy2.c

```
>../string-strcpy2
HELLO
On met une phrase longue
HELmet une phrase longue
HELLO
```

Comparaison de chaînes de caractères

- Pour tester si deux chaînes de caractères sont égales :
  - `int strcmp(const char *s1, const char *s2);`
- Cette fonction renvoie 0 si les chaînes pointées par s1 et s2 sont égales
- Si les deux chaînes sont différentes, elle va renvoyer :
  - un entier strictement positif si s1 est strictement plus grande que s2
  - un entier strictement négatif si s1 est strictement plus petite que s2
- Qu'est ce que veut dire s1 strictement plus grande que s2 ?
  - On prend l'ordre lexicographique (en gros l'ordre du dictionnaire)
  - Si les caractères de s1 sont a1 a2 ... ak et les caractères de s2 sont b1 ... bn alors s1 > s2 si et seulement si
    - Il existe i entre 1 et k tel que :
      - soit i=n+1 et a1=b1,..., a(i-1)=b(i-1)
    - soit i<=n et ai>bi et a1=b1,..., a(i-1)=b(i-1)
- La comparaison entre caractères est celle du dictionnaire (ie 'a'<'b'<'c'...) et les letttres majuscules sont plus **petites** que les lettres minuscules.

Exemple

```
#include <stdio.h>
#include <stdlib.h>
#include <string.h>
#include <assert.h>

int main () {
  char *st1=malloc(30*sizeof(char));
  char *st2=malloc(100*sizeof(char));
  strcpy(st1,"HELLO");
  strcpy(st2,"AB");
  int diff=strcmp(st1,st2);
  if(diff==0){
    printf("%s égale %s\n",st1,st2);
  }else if(diff>0){
    printf("%s plus grande que %s\n",st1,st2);
  }else if(diff<0){
    printf("%s plus petite que %s\n",st1,st2);
  }
  return EXIT_SUCCESS;
}
```

string-strcmp.c

```c
#include <stdio.h>
#include <stdlib.h>
#include <string.h>
#include <assert.h>

int main () {
  char *st1=malloc(30*sizeof(char));
  char *st2=malloc(30*sizeof(char));
  strcpy(st1,"");
  strcpy(st2,"");
  while(strcmp(st1,"QUIT")!=0){
    puts("Entrez chaine 1");
    char *ret=fgets(st1,29,stdin); //lit 29 caractère de stdin (peut mettre le \n)
    assert(ret!=NULL);
    if(st1[strlen(st1)-1]=='\n'){
      st1[strlen(st1)-1]='\0';
    }

    if(strcmp(st1,"QUIT")==0){
      break;
    }
    puts("Entrez chaine 2");
    ret=fgets(st2,29,stdin);
    assert(ret!=NULL);
    if(st2[strlen(st2)-1]=='\n'){
      st2[strlen(st2)-1]='\0';
    }

    int diff=strcmp(st1,st2);
    if(diff==0){
      printf("%s égale %s\n",st1,st2);
    }else if(diff>0){
      printf("%s plus grande que %s\n",st1,st2);
    }else if(diff<0){
      printf("%s plus petite que %s\n",st1,st2);
    }
  }
  return EXIT_SUCCESS;
}
```

string-strcmp2.c

Traduction

- Pour traduire une chaîne de caractères en un entier
  - `int atoi(const char *str);`
- Cette fonction renvoie un entier
- Elle ne prend pas en compte les caractères d'espacement ' ','\n','\r'
- Elle s'arrête au premier caractère qui n'est pas un chiffre

sprintf

- La fonction :
  - **`int sprintf(char * restrict str, const char * restrict format, ...);`**
- Met principe que printf sauf qu'elle met le résultat dans la chaîne str

```
char *s=malloc(30*sizeof(char));
int x=10 ;
sprintf(s,"L'entier %d",x);
```

- Renvoie une valeur négatif en cas de problème

Exemple

```
#include <stdio.h>
#include <stdlib.h>
#include <string.h>
#include <assert.h>

int main () {
  char *s=malloc(30*sizeof(char));
  int x=10;
  int r=sprintf(s,"L'entier %d",x);
  assert(r>=0);
  printf("%s\n",s);
  return EXIT_SUCCESS;
}
```

string-sprintf.c

Fonction de test sur les caractères

Name	Meaning	C locale	Extended
`islower`	Lowercase	`'a' ··· 'z'`	Yes
`isupper`	Uppercase	`'A' ··· 'Z'`	Yes
`isblank`	Blank	`' ', '\t'`	Yes
`isspace`	Space	`' ', '\f', '\n', '\r', '\t', '\v'`	Yes
`isdigit`	Decimal	`'0' ··· '9'`	No
`isxdigit`	Hexadecimal	`'0' ··· '9', 'a' ··· 'f', 'A' ··· 'F'`	No
`iscntrl`	Control	`'\a', '\b', '\f', '\n', '\r', '\t', '\v'`	Yes
`isalnum`	Alphanumeric	`isalpha(x)||isdigit(x)`	Yes
`isalpha`	Alphabet	`islower(x)||isupper(x)`	Yes
`isgraph`	Graphical	`(!iscntrl(x)) && (x != ' ')`	Yes
`isprint`	Printable	`!iscntrl(x)`	Yes
`ispunct`	Punctuation	`isprint(x)&&!(isalnum(x)||isspace(x))`	Yes

Pris de Modern C de Jens Gustedt